

AkıllıRehber: Lise Düzeyi Eğitim İçin Mikroservis Tabanlı Bir RAG Yaklaşımı

Engin Dalga, Serkan Ballı

Özet

Çalışmamızda, lise düzeyi öğrencilerin derslerinde destek alabilecekleri, öğretmen denetimli ve mikroservis mimarisi üzerine inşa edilmiş bir yazılım olan AkıllıRehber sistemi sunulmuştur. Öğretmenlerin kendi ders içeriklerini kolaylıkla oluşturabilecekleri ve sistem parametrelerini esnek biçimde yapılandırabilecekleri bir ortam tasarlanmıştır. Literatürdeki çalışmalar incelendiğinde, çoğunlukla statik olarak yüklenen ve belirli bir konuya odaklanan veri kümeleri üzerinden sistemlerin geliştirildiği görülmektedir. Bu bağlamda AkıllıRehber, öğretmen tarafından dinamik olarak oluşturulabilen ders oturumlarıyla özgün bir yaklaşım sunmaktadır. Sistemin değerlendirilmesinde kullanılan RAGAS çerçevesi, öğretmen paneline entegre edilerek, oluşturulan ders oturumlarının test edilmesine ve gerekli optimizasyonların yapılmasına olanak sağlamıştır. RAGAS değerlendirmeleri iki aşamada gerçekleştirilmiştir. İlk aşamada Türkçe altyapılı Bilişim Teknolojileri ders dokümanları kullanılarak yapılan testlerde ortalama başarı oranı %81.1 olarak ölçülmüştür. İkinci aşamada ise İngilizce altyapılı biyoloji ders dokümanlarıyla gerçekleştirilen değerlendirmede bu oran %88'e ulaşmıştır. Elde edilen sonuçlar, AkıllıRehber sisteminin gerçek kullanım senaryoları için yeterli bir olgunluk seviyesine sahip olduğunu ve aynı zamanda geliştirilmeye açık bir yapı sunduğunu ileri sürmektedir.

Anahtar Kelimeler: İçerik Aktarımlı Üretim (RAG), Kişiselleştirilmiş Eğitim, Türkçe Doğal Dil İşleme, Mikroservis Mimarisi, Halüsinasyon Kontrolü.

1. Giriş

Lise düzeyindeki eğitim ortamlarında, teknolojik gelişmelerle birlikte öğrencilerin öğrenme biçimleri ve beklentileri önemli ölçüde değişmiştir. Bu değişim, klasik eğitim anlayışının tek başına öğrencilerin bireysel ihtiyaçlarını karşılamada yetersiz kalmasına ve eğitim süreçlerine destekleyici yeni çözüm arayışlarının gündeme gelmesine neden olmuştur. Bu bağlamda, öğrencilerin ders saatleri dışında da kullanabilecekleri, bireysel öğrenme hızlarına ve ihtiyaçlarına uyum sağlayabilen kişiselleştirilmiş eğitim ortamlarının oluşturulması önemli bir gereksinim hâline gelmiştir [1], [2].

Son yıllarda büyük dil modellerinin gelişimi, soru-cevap tabanlı eğitim sistemlerinde önemli bir dönüşüm yaratmıştır [1]. Doğal dil anlama ve üretme yetenekleri sayesinde LLM tabanlı sistemler, öğrencilerin serbest biçimde sordukları sorulara anlık ve açıklayıcı yanıtlar üretebilmekte; bu durum, öğrenme süreçlerinin daha etkileşimli ve erişilebilir hâle gelmesine katkı sağlamaktadır. Bu tür sistemler, özellikle bireysel çalışmalarda öğrencinin ihtiyaç duyduğu akademik desteği anında sunabilme potansiyeli ile dikkat çekmektedir.

Bununla birlikte, LLM tabanlı soru-cevap sistemlerinin doğrudan kullanımı, modelin eğitildiği genel bilgi kümesine dayalı yanıtlar üretmesi nedeniyle doğruluk ve güvenilirlik açısından bazı sınırlılıklar barındırmaktadır. Bu sorunun aşılabilmesi için, yanıt üretim sürecinde alanla ilişkili dokümanlardan bağlam oluşturulması ve ilgili bilgilerin modele dinamik olarak aktarılması kritik bir gereksinim olarak ortaya çıkmıştır. Bu yaklaşım, modelin yalnızca genel bilgiyi değil, belirli bir ders veya konuya özgü içerikleri temel alarak yanıt üretmesini mümkün kılmaktadır[1], [3].

Bu çalışmada, lise düzeyi öğrencilerin ders saatleri dışında kişiselleştirilmiş eğitim desteği alabilmelerini amaçlayan bir soru-cevap (Q/A) asistan sistemi önerilmektedir. Öğretmenler, geliştirilen sistem üzerinden kendi derslerine ait dokümanları yükleyebilmekte; öğrenciler ise bu içerikler doğrultusunda ilgili derslere yönelik sorularına yanıt alabilmektedir. Uluslararası literatür incelendiğinde, kullanıcılar tarafından dinamik olarak güncellenebilen dokümanlara dayalı, aynı zamanda büyük dil modeli, gömme (embedding) yöntemi ve erişim bileşenleri açısından kişiselleştirilebilir bir RAG sistemine sınırlı sayıda örnekte rastlanmaktadır[3]. Türkiye bağlamında ise RAG temelli çalışmaların oldukça sınırlı olduğu, özellikle lise düzeyi eğitimi odağına alan yaklaşımların literatürde yeterince ele alınmadığı görülmektedir[4].

Bu bağlamda çalışma, aşağıdaki araştırma sorularına yanıt aramaktadır:

AS1. AkıllıRehber RAG sistemi, bağlam desteği olmadan kullanılan ham büyük dil modeline kıyasla anlamsal doğruluk, müfredat uyumluluğu ve halüsinasyon kontrolü açısından ne düzeyde bir performans farkı sunmaktadır?

AS2. RAG tabanlı soru-cevap sistemlerinin performansı, farklı dil altyapılarına sahip ders materyalleri kullanıldığında nasıl bir değişim göstermektedir?

AS3. RAG tabanlı eğitim asistanlarının değerlendirilmesinde, otomatik metriklere dayalı bir ölçüm yaklaşımı anlamlı ve uygulanabilir bir değerlendirme çerçevesi sunmakta mıdır?

2. İlgili Çalışmalar

Büyük dil modellerinin eğitimde kullanımı, öğrencilere kişiselleştirilmiş bir eğitim ortamı sunma potansiyeliyle literatürde geniş yer kaplamaktadır. Ancak bu modellerin ders müfredatı dışında yanıtlar üretebilmesi ve halüsinasyon gibi sorunlar, araştırmaları İçerik Aktarımlı Üretim (RAG) mimarilerine yöneltmiştir. Literatürde bulunan LPITutor ve Mooc RAG gibi çalışmalar RAG mimarisinin kişiselleştirilmiş öğrenme deneyimi oluşturma konusundaki etkili olduğunu kanıtlamıştır [5]. Bu çalışmalar da genellikle sabit bir veri tabanı üzerinden yanıt üretimi gerçekleştirilmektedir. Birden fazla dersin ya da kurs içeriğinin sisteme eklenebildiği ve kontrolü öğretmene bırakan yapılar literatürde kısıtlıdır [1], [3], [6].

Türkiye bağlamındaki RAG çalışmaları incelendiğinde konuyla sınırlı sayıda çalışma olduğu görülmektedir. Üniversite düzeyinde akademik danışmanlık amacıyla oluşturulan EkoBot[4], kampüste öğrencilerin sorularını cevaplamayı hedefleyen UniRobo[7] ve finansal eğitimi ve finansal uzmanlık gerektiren Türkçe verilere odaklan TULIP[9] bunlara örnek olarak verilebilir. Ancak bu çalışmaları incelediğimizde statik bir içerik üzerine kurulu olduklarını ve öğretmen- öğrenci odağını konu alan makalelerin bulunmadığını görmekteyiz.

Mevcut literatürdeki bu genel eğilim, RAG tabanlı sistemlerin belirli bir kurum ya da sabit konular üzerine özelleştirildiğini, ancak bu durumun eğitimin dinamik yapısına tam olarak uyum sağlayamadığını göstermektedir. Özellikle lise düzeyindeki kişiselleştirilmiş eğitim senaryolarında, öğretmenlerin ders materyallerini anlık olarak güncelleyebilecekleri ve teknik ayarları kendi ihtiyaçlarına göre yapılandırabilecekleri esnek bir mimariye ihtiyaç duyulmaktadır. Tablo 1, literatürde öne çıkan yerel ve uluslararası çalışmaların teknik yapısını ve uygulama alanları bakımından karşılaştırmasını göstermektedir [3].

Tablo 1. Eğitim Odaklı RAG Sistemlerinin Karşılaştırmalı Literatür Analizi

Çalışma	Yıl	Ülke	Alan	LLM	Değerlendirme	Temel Katkı / Fark
MAGI [8]	2024	ULUS.	Somutlaştırılmış Öğrenme	Llama 3 8B	Animasyon Kalitesi	3D avatar entegrasyonu ve görsel öğrenme
Gaita [2]	2024	ULUS.	Kişiselleştirilmiş Bilgisayar Bilimleri Eğitimi	ChromaDB, Gemma3-12 DeepSeek-r 1-14B,	-	Kişiselleştirilmiş CS eğitimi için RAG sistemi
UniRobo [7]	2024	TR	Kampüs Bilgi Sistemi	OpenAI API	Kullanıcı Memnuniyeti	İnce ayar (fine-tuning) ile alan adaptasyonu.
EkoBot [4]	2025	TR	Akademik Danışmanlık	GPT-4o	%82 Doğruluk	İlk Türkçe akademik RAG sistemi örneği.
LPITutor [1]	2025	ULUS.	Kişiselleştirilmiş Eğitim	GPT-3.5	%94 Doğruluk	Çift katmanlı istem mühendisliği
TULIP [9]	2025	TR	Finans Eğitimi	Llama 3.1 / Qwen 2.5	-	Sürekli ön eğitim (continual pre-training) yaklaşımı.
MOOC RAG [5]	2025	ULUS.	Online Kurslar	GPT-4	-	Çevrim içi kurslarda kullanıcı davranış analizi.

Tablo 1’de özetlenen çalışmalar incelendiğinde bazı kısıtlılıklar dikkate çarpmaktadır. Bunlardan ilki mevcut çalışmaların belli bir kurum ya da konu odaklı olması ve dinamik içerik sunamamasıdır. Diğer bir problem teknik altyapının geliştiriciler tarafından ayarlanması ve statik olarak bırakılmasıdır. Ayrıca bildiğimiz kadarıyla literatürde lise düzeyindeki Türk eğitim sistemine uyarlanmış bir RAG mimarisi bulunmamaktadır [3].

3. SİSTEM MİMARİSİ VE GENEL ÇALIŞMA İLKELERİ

Bu bölümde, geliştirdiğimiz AkıllıRehber sisteminin mimari tasarımı ve temel işleyiş yapısı detaylı olarak incelenmiştir. Mevcut sistem, öğretmen ve öğrenci rollerini merkeze alan bir yapı sunmaktadır. Sistemin temelinde Retrieval Augmented Generation ile bilgiye erişim ve yanıt üretimi yatmaktadır. Sistemin genel akış şeması, teknik bileşenleri ve tasarım gerekçeleri sırasıyla incelenecektir.

3.1. RAG Tabanlı Genel Sistem Akışı

Sistem mimarisinin temel amacı LLM'in doğrudan yanıt üretimindeki olası halüsinasyon sorununu azaltmak ve öğretmen tarafından sunulan kaynaklardan oluşan bağlam sayesinde yanıtın doğruluğunu arttırmaktır.

Sistemin temel akışı öğretmenin bir ders oturumu oluşturmasıyla başlar. Bu dersle ilgili dökümanlar pdf ya da markdown olarak sisteme yüklenir. Pdf olarak yüklenen dosyalar işlemde geçirilerek sistemin kullanımına uygun markdown formatına dönüştürülür. Daha sonra markdown dosyaları Türkçe dil yapısına uygun ve LLM'in işlemlerini kolaylaştıracak küçük parçalara bölünür. Chunk adı verilen bu parçalar arama süreçlerinde kullanılmak üzere vektörel ifadelerle dönüştürülerek chromadb veritabanında kayıt altına alınır. Böylece oluşturulan her ders için özgün bir bilgi tabanı sağlanmış olur.


Öğrenci tarafında yapılan sorgu sistemin algılayacağı vektörel ifadeye dönüştürülür ve seçili ders oturumundaki vektör veri tabanı üzerinden arama yapılarak benzerlik puanlarına (cosine similarty) göre en yakın 5 bilgi parçası getirilir. Bu bilgi parçaları benzerlik sırasına göre birleştirilerek LLM'e iletilir ve LLM bu bilgi parçalarını ve özelleştirilmiş sistem promptunu kullanarak bir yanıt döndürür.

Öğretmenin rolü, bu RAG tabanlı işlem hattının ayarlanması ve denetimidir. Öğretmen ihtiyaçlara göre LLM modelini ya da vektör işlemlerinde kullanılan embedding modelini değiştirebilir. Hatta bağlamların geçerliliğinin ve yeniden sıralanmasının kontrolünü sağlayan yeniden sıralama(re-ranker) modelini devreye alabilir. Öğretmenin kontrolünde olan bu mekanizma sistemin sürekliliğini de garanti altına almaktadır.

Öğrencinin rolü ise, sisteme dersle alakalı sorular sorarak cevapları alan son kullanıcı olmasıdır. Öğrenci etkileşimli ile üretilen yanıtlar kaydedilerek, öğrenme sürecinin ve sistem performansının takibi amacıyla kullanılmaktadır.

Bu mimari ile AkıllıRehber, öğretmen denetimini merkeze alan ve tüm kullanıcı rollerini bir RAG tabanlı bilgi akışında birleştiren tutarlı bir yapı sunmaktadır. Bu bilgi akışı

ve yanıt süreci, öğretmen ve öğrenci rollerinin RAG akışındaki konumları ile birlikte Şekil 1’de verilmiştir.




Şekil 1. AkıllıRehber Sistemi RAG Tabanlı Bilgi Akışı

Şekil 1’de AkıllıRehber mimarisinin öğretmen ve öğrenci rollerindeki bilgi akışı ve servislerin kullanımı belirtilmiştir. Bu mimarinin bileşenleri ve teknik altyapısı 3.2. bölümünde ayrıntılı olarak anlatılacaktır.

3.2 Teknik Mimari ve Mikroservis Yapısı

AkıllıRehber sistemi, Şekil 1’deki genel sistem akışına uygun olarak kurgulanan bir mikroservis yapısıyla oluşturulmuştur. Sistemin temelinde bağımsız olarak çalışan 9 adet servis bulunmaktadır. Mikroservis yapısını gösteren teknik mimari Şekil 2’de gösterilmiştir.



Şekil 2. AkıllıRehber Sistemine Ait Mikroservis Tabanlı Teknik Mimari

Şekil 2 de görüldüğü üzere her bir hizmet birbirinden bağımsız olarak çalışmaktadır. Mevcut yapının bir bütün olarak çalışmasından yönetim katmanı sorumludur. Yönetim katmanı aynı zamanda hizmetlerin birbiriyle haberleşmesini sağlayan bir Proxy görevi görür.

Önyüz kimlik doğrulama katmanından yardım alarak öğretmen ve öğrenci arayüzü birbirinden ayırır. Öğretmen tarafında ders oturumlarının oluşturulması, dökümanların yüklenmesi ve RAG sistemine sunulması, gerekli ayarlarının ve optimizasyonların yapılması gibi seçenekler vardır. Ek olarak bu arayüzden öğretmen oluşturduğu oturumla ilgili sorular sorarak sistemi test edebilir. Öğrenci ise sisteme girerek ders oturumunu seçer ve sorular sorarak RAG tarafından oluşturulan cevapları alır. Bu arayüz Nextjs 14 altyapısı ile oluşturulmuştur.

Kimlik Doğrulama Servisi sistemdeki tüm kullanıcıların güvenli bir şekilde tanımlamasını ve yetkilerinin merkezi olarak yönetilmesini sağlar. Kullanıcı hesapları, roller ve izinler bu servis tarafından yönetilmektedir. Python tabanlı FastAPI altyapısını kullanan bu servis, JWT ile token doğrulama mantığı kullanmaktadır.

Dökümanlar Pdf formatında yüklenerek yapısal bir metin formatı olan markdownlara dönüştürülür. Dönüştürme işlemi için marker kütüphanesi kullanılır. Marker dönüştürme işleminde yapay zeka kütüphanelerini kullanan bir yapıdadır. Yüksek işlem gücü ve bellek gerektirir. Marker için yeterli olmayan donanım durumları için fallback olarak pdfplumber kullanılmaktadır. Markdownların parçalanarak yapısı bozulmadan küçük parçalara ayrılması LLM desteği ile kurduğumuz parçalama yapısı tarafından sağlanmaktadır. Bu işlem için kullanılan LLM sağlayıcısı Groq API si üzerinde bulunan llama3.1 8b modeli hem hızlı yanıt vermesi hemde düşük maliyet sebebiyle tercih edilmiştir. Bir sistem promptu aracılığıyla Türkçe dilbilgisi kurallarına uyarak ve mevcut başlık ve konu bütünlüklerini bozmadan dökümanı 600-2000 karakter aralığında parçalara ayırması talimatı verilir. Örnek bir parça yapısı Şekil 3’de gösterilmiştir.

```
## Sayfa 92
İç Donanım Birimleri
Anakartı ve donanım birimlerini bilgisayar kasası içine monte ediniz. Gerekli
olan bağlantıları yaparak bilgisayarı çalışır hâle getiriniz.
Gereksinimlerimiz: Anakart, bilgisayar kasası, işlemci, soğutucu sistemi, RAM
bellek, ekran kartı, ses kartı, Ethernet kartı, sabit sürücü, optik sürücü, SATA /
3.16
PATA kablosu.
Adım 1: Anakartı, kasa içine yerleştiriniz ve vidalarını sabitleyiniz.
Adım 2: Aşağıdaki aygıtları anakart üzerine yerleştiriniz ve sabitleyiniz.
• İşlemci
• RAM bellek
• Ekran kartı
• Ses kartı
• Ethernet kartı
• Sabit sürücüler (HDD, SSD, optik disk sürücüleri)
Adım 3: ATX güç bağlantılarını yapınız.
Adım 4: Ön panel bağlantılarını yapınız. Gerekli ise anakart kullanım kılavuzuna
bakınız.
Adım 5: Kontrollerinizi yapınız.
Adım 6: Öğretmeninizin kontrolünde bilgisayara güç vererek test ediniz.
Değerlendirme
Hazırlayacağınız görsel materyal, aşağıdaki listede yer alan ölçütlere göre değerlendirilecektir.
Çalışmanızı yaparken bu ölçütleri dikkate alınız.
```

Şekil 3. LLM Destekli Parçalama Sonucu Oluşturulan Örnek Markdown Parça Yapısı

Şekil 3’de görüldüğü üzere başlıklar ve konu bütünlüğü korunarak markdown formatında bir yapısal bozulma olmadan parçalama işlemi gerçekleştirilmektedir. Sonraki aşamada doküman parçaları embedding işlemi uygulanarak vektör uzayında temsil edilir. Embedding modeli olarak Alibaba tarafından sağlanan text-embedding-v4 (1024boyut,100+ dil desteği) tercih edilmiştir. Alternatif kullanım için Openrouter sağlayıcısındaki text-embedding-3-small(1536 boyut) eklenmiştir. Buradaki tercih sebebi Türkçe metinleri anlamsal olarak algılayabilecek ve yüksek parametrelili modeller olmasıdır. Vektörlerin saklanması için Chromadb veritabanı tercih edilmiştir.

Yeniden sıralama(re-ranking) hizmeti mevcut sistemde oluşturulan anlamsal benzerlik oranlarına ek olarak kullanılabilecek bir iyileştirme katmanı olarak düşünülmüştür. RAG yapısı üzerinde bir arama yapıldığında yeniden sıralama katmanı mevcut sıralamayı tekrar değerlendirerek kendi kriterlerine göre bir yeniden sıralama gerçekleştirir. Bu hizmetin kullanımı isteğe bağlıdır ve mevcut ders oturumu üzerinden aktifliği değiştirilebilir.

Kişiselleştirme hizmeti dersle ilgili talimatları, öğretmenin verdiği özel promptları ve öğrencinin soru geçmişini dikkate alarak öğrencinin seviyesine ve dersin hedeflerine uygun çıktılar üretilmesinde kullanılır. Bu servisin kullanımı da isteğe bağlıdır ve ders ayarlarından etkinliği değiştirilebilir.

LLM Servisi RAG sistemi tarafından oluşturulan bağlamları ve sistem promptunu alarak cevabın üretildiği yerdir. Oluşturulan cevabın bağlama bağlı kalması ve halüsinasyonun önlenmesi için System Promptu kullanılır. LLM sağlayıcısı olarak Openrouter, Groq, Alibaba, Openai ve Deepseek entegre edilmiştir. Bu sağlayıcılar üzerindeki modeller ihtiyaca göre

ayarlanılarak kullanılabilir. Model seçimindeki esneklik öğretmene dersin ihtiyaçlarına göre farklı seçimler yaparak en iyi sonuca ulaşma imkânı vermektedir.

3.3. Mimari Özeti

Akıllı Rehber mimarisi, hem performans hemde geliştirilebilirlik seçenekleri dikkata alınarak kurulmuştur. Mikroservisler arasındaki iletişimin yönetim servisi tarafından sağlanması, sisteme yeni özellikler eklenmesi ve performans iyileştirmeleri sağlanmasını kolay uygulanabilir kılmaktadır. Bu esneklik geliştirdiğimiz sistemin hibrit bir RAG yapısına çevrilmesine temel oluşturmaktadır.

4. DENEYSEL KURULUM

Bu çalışmada sistem performansını değerlendirmek için fiziksel metin karşılaştırmalarını baz alan metrikler yerine, anlamsal değerlendirmeyi kullanan RAGAS [10] çerçevesi tercih edilmiştir. Literatürde yaygın olarak rastladığımız Bleu [11], Rogue [12] ve F1-score [13] gibi metrikler üretilen yanıtların referans metinlerle fiziksel olarak örtüşmesini ölçmektedir. Bu da anlamsal olarak doğru ama farklı kelimelerle ya da cümlelerle ifade edilen yanıtların düşük skorlar üretmesine sebep olmaktadır. Mevcut sistemimizin eğitim ortamına yönelik geliştirilen bir RAG altyapısı olduğunu düşündüğümüzde, ifadelerin birebir benzemesinden ziyade anlamsal olarak yakınlıklarını değerlendirmenin daha doğru sonuçlar üreteceği düşüncesiyle test ortamı için RAGAS çerçevesini kullandık. Bu çerçevede kullanılan metrikler Tablo 2’de gösterilmiştir.

Tablo 2: RAGAS Çerçevesinde Kullanılan Anlamsal Değerlendirme Metrikleri ve Kullanım Amaçları

Metrik	Ne Ölçer?	Tipik Kullanım
Answer Faithfulness	Cevabın, sağlanan bağlamdaki (context) bilgilere ne kadar sadık olduğunu ölçer (Halüsinasyon kontrolü).	Yüksek riskli alanlar (Tıp, Telekom, Hukuk), doğruluk kritikliği.
Answer Relevance	Üretilen cevabın, sorulan soruyla ne kadar alakalı ve doğrudan olduğunu ölçer.	Genel QA kalitesi, kullanıcı memnuniyeti, cevap verimliliği.
Context Relevance / Precision	Getirilen dokümanların (chunklar) soruya ne kadar uygun ve doğru olduğunu ölçer.	Retriever seçimi, chunking stratejisi ve re-ranker optimizasyonu.

Metrik	Ne Ölçer?	Tipik Kullanım
Context Recall	Geri getirilen bağlamanın, sorunun cevabı için gereken bilginin ne kadarını kapsadığını ölçer.	"Kaç chunk getirilmeli?" veya "Retriever bilgiyi bulabiliyor mu?" soruları.
Answer Correctness / Factual Correctness	Üretilen cevabın (varsa) "altın cevap" (ground truth) ile anlam düzeyinde ne kadar örtüştüğünü ölçer.	Benchmark QA veri setleri ile karşılaştırma, model performansı kıyaslama.

Tablo 2’de açıklanan metrikler RAG sisteminin çalışmasını anlamsal değerlendirme yöntemleri kullanarak değerlendirmeyi amaçlar. Test ortamının oluşturulması için RAGAS ayrı bir mikroservis olarak mimariye eklenmiştir. Test ortamının yönetilmesi ve sonuçların alınmasında kullanılacak arayüz öğretmen paneli üzerinden entegre edilmiştir. Böylece öğretmenlerin kendi oluşturdukları ders oturumlarını da değerlendirebilecekleri bir ortam oluşturulmuştur.

Deney ortamı için öğretmen yetkili bir hesap oluşturularak, Bilişim Teknolojileri Temelleri 9. Sınıf ders oturumu tanımlanmıştır. MEB tarafından sunulan ders kitabı pdf formatında sisteme yüklenmiştir. 258 sayfadan oluşan bu pdf dosyası, RAG sisteminde işlenebilmesi amacıyla markdown formatına dönüştürülmüştür.

Embedding modeli olarak, literatürde RAGAS tabanlı değerlendirme çalışmalarında sıklıkla tercih edildiği gözlemlenen OpenAI tarafından sunulan text-embedding-3-small modeli seçilmiştir. RAGAS metriklerinin hesaplanmasında kullanılan değerlendirme amaçlı LLM olarak ise, düşük maliyet ve hızlı yanıt süresi gibi pratik kriterler göz önünde bulundurularak OpenAI gpt-4o-mini modeli tercih edilmiştir.

Dersle ilgili pdf dokümanı Google Gemini’ye verilerek, doküman içerisinden farklı zorluk seviyelerinde ve içeriğe tamamen bağlı kalacak şekilde 50 adet soru-cevap çifti oluşturulması istenmiştir. Oluşturulan soru-cevap çiftleri, testin geçerliliğini etkilememesi amacıyla herhangi bir müdahalede bulunulmadan deney arayüzüne yüklenmiştir.

Deney süresince elde edilen gözlemler doğrultusunda test sürecinin iki aşamada gerçekleştirilmesine karar verilmiştir. Mevcut veri seti üzerinde yapılan değerlendirmeler ve elde edilen bulgular, RAGAS testinin bazı parametrelerde Türkçe içerikleri yeterince doğru değerlendirmedini düşündürmüştür. Bu nedenle, İngilizce ders dokümanları kullanılarak yeni

bir veri seti oluşturulması ve elde edilen bulguların karşılaştırmalı olarak incelenmesi fikri ortaya çıkmıştır.

Bu kapsamda bir Biyoloji ders oturumu oluşturulmuş, 265 sayfadan oluşan İngilizce biyoloji dokümanı derse yüklenmiş ve gerekli RAG ayarları yapılarak sistem test için hazır hâle getirilmiştir.

Mevcut veri setleri üzerinden elde edilen sonuçların değerlendirilmesi ve karşılaştırılması Bulgular bölümünde sunulmuştur.

5. BULGULAR

AkıllıRehber sistemimizin ilk deneysel değerlendirmesi kapsamında, RAGAS testi sonucunda elde edilen bulgular bu bölümde incelenmiştir. RAGAS metrikleri baz alınarak, 50 soru-cevaptan oluşan veri seti üzerinden hesaplanan ortalama değerler Tablo 3’de sunulmuştur.

Tablo 3. İlk RAGAS Değerlendirmesi Sonucunda Elde Edilen Ortalama Metrik Değerleri

Metrik	Skor (%)	Tanım
Faithfulness	%93.6	Üretilen cevabın, getirilen bağlam (context) içindeki bilgilerle tutarlılığını ölçer.
Answer Correctness	%59.1	Üretilen cevabın, referans cevap (ground truth) ile olan anlamsal ve olgusal örtüşmesini ölçer.
Answer Relevancy	%57.4	Üretilen cevabın, sorulan soruya ne kadar doğrudan ve ilgili yanıt verdiğini ölçer.
Context Precision	%95.5	Getirilen döküman parçalarının (chunks) soruyla olan alakasını ve sıralama kalitesini ölçer.
Context Recall	%100.0	Referans cevabı oluşturmak için gereken bilginin dökümandan getirilme oranını ölçer.
Genel Skor	%81.1	Tüm değerlendirme metriklerinin ağırlıklı ortalamasını ifade eder.

Tablo 3’deki sonuçlara baktığımızda AkıllıRehber sistemimizin en yüksek başarı gösterdiği metriğin Context Recall (%100) olduğu görülmektedir. Bu sonuç, AkıllıRehber

sistemin cevabı bulmak için ihtiyaç duyduğu bilgiyi bağlamdaki dökümanlardan bulma konusundaki hassasiyetini belirtmektedir.

Context Precision değerinin %95.5 olması, vektörel arama (cosinus similarty) sonucunda getirilen doküman parçalarının soruyla alakalı olduğunu ve doğru sıralandığını göstermektedir. Bu iki metriğin yüksek olması sistemin doküman içerisindeki farklı yerlerden bilgi getirme konusundaki hassasiyetini göstermektedir.

Sistemin dökümana olan sadakatini gösteren Faithfulness (%93.6) değeri ise cevapların bağlam dışına çıkmadığını bu da halüsinasyon oranının çok düşük olduğunu göstermektedir.

Yukarıdaki 3 metriği birlikte değerlendirdiğimizde sistemin güvenilir bir bilgi kaynağı olarak çalıştığını söyleyebiliriz.

Üretilen cevabın anlamsal olarak gerçek cevap ile uyumunu gösteren Answer Correctness metriği %59.1 gibi düşük bir sonuç vermiştir. Bununla alakalı olarak soru bazı incelediğimizde bazı önemli bulgular elde ettik.

Bir örnekte “Yazılım korsanlığı nedir?” sorusuna cevap olarak “Korsan yazılım kullanmak” verilmiş. Pdf dökümanı incelediğimizde soruyla alakalı olabilecek tek bilginin cevapta verildiği şekilde olduğu ve doküman içerisinde konuyla alakalı başka bir bilginin olmadığını gözlemledik. Bu aslında sistemin bağlama bağlı olarak oluşturabileceği en doğru cevabı verdiğini göstermektedir. Burdan gelen %12.2 lik Answer Correctness skoru parametredeki ortalama değeride önemli ölçüde düşürmüştür.

“Faydalı model belgesinin koruma süresi kaç yıldır” sorusuna RAG sistemi üzerinden cevap üretilenmemiştir. Bilginin ders dökümanında bulunamadığı cevabını vererek halüsinasyon engellenmiştir. Anca buradaki gerçek cevaba bakıldığında “Ürünü 10 yıl üretme ve pazarlama hakkı verir.” Şeklinde olduğunu görmekteyiz. Burada cevap dönmemesinin sebebi RAG sisteminin koruma süresi ile üretme ve pazarla hakkı arasında anlamsal bir bağlantı kuramamasıdır. Bu sebeple bu metrik %6.2 lik bir sonuç üretmiştir.

Diğer bir örnekte “HDMI portunun VGA portuna göre üstünlüğü nedir?” sorusuna sistem dökümandan bulduğu doğru cevabı vermiştir. Ancak test ortamına sunduğumuz cevapla örtüşmediği için buradaki değerde %13.1 de kalmıştır.

Yukarıdaki örneklere ve Ek1’deki RAG testi detaylı sonuç raporuna baktığımızda aslında Answer Correctness metriğinin düşük değerler, sistemin halüsinasyon üretmeme gayretinden kaynaklanmaktadır.

Answer Relevancy ortalama değeri %57.4 olarak ölçülmüştür. Bu değer literatürdeki genel ortalamanın altındadır. Bu metriğin neden düşük kaldığını tespit etmek amacıyla soru bazlı incelemeler gerçekleştirdik.

“Bilgi güvenliğinde gizlilik ilkesi neyi kapsar?” sorusuna sistemin cevabı “Bilgi güvenliğinde gizlilik ilkesi, bilgilerin yetkisiz kişilerin eline geçmemesini kapsar.” Olmuştur. Sisteme sunduğumuz gerçek cevap ile sistemin cevabı anlamsal olarak örtüşmektedir ve cevapta gereksiz ayrıntıda bulunmamaktadır. Buna rağmen Answer Relevancy metriği %52 gibi ortalamanın altında bir değer üretmiştir.

“En çok bilinen altı etik ilke hangileridir?” sorusuna sistemin cevabı “Dürüstlük, adalet, ahlak, vicdan, onur ve sorumluluk.” Dur. Buradada sisteme sunulan gerçek cevapla sistemin cevabın örtüştüğü sadece sıralamanın farklı olduğu gözlenmiştir. Buna rağmen Answer Relevancy metriği %38.4 gibi çok düşük bir değer üretmiştir.

“Yazılım korsanlığı nedir?” sorusuna ise sistemin cevabı “Korsan yazılım kullanmak.” Dır. Bu aslında her ne kadar geçerli bir cevap olmasada sisteme sunulan doküman incelendiğinde konu ile alakalı olarak dökümandan gelebilecek en yakın cevaptır. Çünkü bu konuyla alakalı doküman içerisinde başka bilgi bulunmamaktadır. Bu da sistemin dökümana sadık kalmak için bu cevabı ürettiğini göstermektedir. Ancak Answer Relevancy burada %0 değerini üretmiştir.

Answer Relevancy metriğine ilişkin yapılan diğer incelemelerde de benzer gözlemler elde edilmiştir. Bu nedenle, söz konusu metriğin Türkçe ders dokümanları üzerinde gerçekçi sonuçlar üretip üretmediğinin daha sağlıklı biçimde değerlendirilebilmesi amacıyla ikinci bir testin gerçekleştirilmesine karar verilmiştir.

Bu kapsamda, İngilizce dilinde biyoloji ders dokümanları kullanılarak yeni bir ders oturumu oluşturulmuş; RAGAS testi için doküman içeriğine bağlı alınarak 50 adet soru–cevap çifti hazırlanmış ve ikinci test süreci yürütülmüştür. Gerçekleştirilen bu testten elde edilen sonuçlar Tablo 3’te sunulmuştur.

Tablo 4. İngilizce Ders Dokümanları ile Gerçekleştirilen İkinci RAGAS Değerlendirmesi Sonuçları

Metrik	Skor (%)
Faithfulness	% 97.5
Answer Relevancy	%81.4

Metrik	Skor (%)
Answer Correctness	%69.9
Context Precision	%93.4
Context Recall	%98.0
Genel Skor	%88.0

Tablo 4'te elde edilen sonuçlar incelendiğinde, İngilizce dilindeki ders dokümanları kullanılarak oluşturulan veri setinde, Türkçe değerlendirmeye kıyasla metrik değerlerinde belirgin bir artış olduğu görülmektedir. Genel skorun %81,1'den %88,0 seviyesine yükselmesi, ikinci testte sistem çıktılarının daha tutarlı biçimde değerlendirilebildiğini göstermektedir.

Türkçe değerlendirmede görece düşük kalan Answer Relevancy metriğinin, İngilizce veri setinde %81,4 seviyesine yükselmesi dikkat çekici bir sonuçtur. Soru bazında yapılan incelemelerle birlikte değerlendirildiğinde, bu artışın söz konusu metriğin Türkçe içeriklerde dilsel yapıya bağlı olarak daha düşük skorlar üretebilmesinden kaynaklanabileceği düşünülmektedir.

İngilizce ders dokümanları kullanılarak oluşturulan biyoloji dersi test veri seti değerlendirildiğinde, genel ortalamanın iyi seviyede olduğu görülmektedir. Diğer metriklerle kıyasla nispeten daha düşük kalan Answer Correctness ve Answer Relevancy metriklerine ait sonuçlar soru bazında incelendiğinde, bu durumun Türkçe için özel olarak iyileştirdiğimiz sistem promptuna benzer optimizasyonların İngilizce içerikler için uygulanmamış olmasından kaynaklanan küçük hatalardan oluştuğu gözlemlenmiştir.

6. TARTIŞMA

Bu çalışmada geliştirilen AkıllıRehber sistemi, RAGAS değerlendirme metrikleri kullanılarak Türkçe ve İngilizce ders dokümanları üzerinde test edilmiş ve elde edilen sonuçlar dil ve içerik yapısına bağlı bazı farklılıklar ortaya koymuştur. Elde edilen bulgular, sistemin bilgiye erişim ve bağlam sadakati açısından tutarlı bir performans sergilediğini, ancak bazı değerlendirme metriklerinin dilsel özelliklere duyarlı davrandığını göstermektedir.

Türkçe ders dokümanları ile gerçekleştirilen ilk değerlendirmede Context Recall, Context Precision ve Faithfulness metriklerinin yüksek değerler üretmesi, sistemin ilgili bilgiyi doğru biçimde geri getirebildiğini ve üretilen yanıtların bağlam dışına çıkmadığını ortaya koymaktadır. Bu durum, RAG tabanlı mimarının halüsinasyon üretimini sınırlandırma

hedefiyle uyumlu bir davranış sergilediğini göstermektedir. Literatürde RAG tabanlı sistemler için önerilen temel tasarım ilkeleri göz önünde bulundurulduğunda, bu metriklerin birlikte yüksek değerler üretmesi sistemin güvenilir bir bilgi akışı sunduğuna işaret etmektedir.

Buna karşın, Answer Correctness ve Answer Relevancy metriklerinin Türkçe değerlendirmede görece düşük değerler üretmesi dikkat çekicidir. Soru bazında yapılan incelemelerde, sistem tarafından üretilen bazı yanıtların anlamsal olarak doğru ve bağlama uygun olmasına rağmen, soruya dolaylı biçimde yanıt verdiği durumlarda düşük skorlarla değerlendirildiği gözlemlenmiştir. Özellikle Türkçe ders dokümanlarında yer alan tanımsal ve açıklayıcı anlatım yapısının, kısa ve doğrudan yanıt üretimini sınırladığı ve bu durumun relevancy temelli metrikleri olumsuz etkileyebildiği değerlendirilmektedir.

Bu gözlemler doğrultusunda, Answer Relevancy metriğinin Türkçe ders materyalleri üzerinde nasıl davrandığını daha sağlıklı biçimde incelemek amacıyla ikinci bir değerlendirme gerçekleştirilmiştir. İngilizce dilinde biyoloji ders dokümanları kullanılarak oluşturulan veri seti üzerinde yapılan testlerde, söz konusu metriğin belirgin biçimde yükselmesi, değerlendirme sonuçlarının dil yapısına duyarlı olabileceğini düşündürmektedir. Literatürde RAGAS metriklerinin çoğunlukla İngilizce veri setleri üzerinde raporlanması ve Türkçe gibi eklemeli diller için sınırlı sayıda çalışmanın bulunması, bu bulgunun anlamlı bir gözlem olarak ele alınmasını gerekli kılmaktadır.

Öte yandan, İngilizce değerlendirmede Answer Correctness ve Answer Relevancy metriklerinin tamamen ideal değerlere ulaşmamış olması, sistem promptunun İngilizce içerikler için Türkçe’de olduğu kadar özelleştirilmemiş olmasından kaynaklanan sınırlılıklarla ilişkilendirilebilir. Bu durum, değerlendirme sonuçlarının yalnızca kullanılan metriklere değil, aynı zamanda prompt tasarımı ve dil-özellik ayarlara da bağlı olduğunu göstermektedir.

Genel olarak değerlendirildiğinde, bu çalışma RAGAS metriklerinin tek başına mutlak performans göstergeleri olarak ele alınmaması gerektiğini; dil yapısı, doküman türü ve sistem konfigürasyonu ile birlikte yorumlanmasının daha sağlıklı sonuçlar üreteceğini ortaya koymaktadır. Elde edilen bulgular, özellikle Türkçe ders materyalleri için RAG tabanlı sistemlerin değerlendirilmesinde dil-özellik yaklaşımların ve uyarlanmış metrik yorumlarının önemini vurgulamaktadır.

7. SONUÇ

Bu çalışmada lise düzeyi eğitimi desteklemek amacıyla oluşturduğumuz RAG tabanlı soru cevap sistemi değerlendirilmiştir. Oluşturulan sistem öğretmenlerin esnek olarak kendi derslerini sisteme aktarabildikleri ve gerekli ayarları yapabildikleri, mikroservis tabanlı bir

yapıdır. RAGAS metrikleri kullanılarak yapılan deneysel çalışmalar ve insan gözlemleri sistemin son kullanıcı seviyesine uygun olarak çalıştığını ancak sistem promptlarına yapılan optimizasyonlarla ve hibrit yaklaşım denenerek daha iyi sonuçlar alınabileceğini göstermektedir. Ayrıca deneysel çalışmalardaki farklı dil yapıları üzerinde değişken sonuçlar alınması insan gözlemleri ile deneyi desteklemenin önemini vurgulamaktadır.

Gelecek Perspektifi

Bu çalışma, ders bağımsız olarak tasarlanmış kişiselleştirilmiş bir RAG tabanlı öğrenme asistanının, lise düzeyindeki eğitim senaryolarında uygulanabilirliğini ortaya koymuştur. Gelecek çalışmalarda, hibrit RAG yaklaşımlarının bilgi erişim ve yanıt üretim performansı üzerindeki etkilerinin incelenmesi planlanmaktadır. Buna ek olarak, görsel ve grafik gibi metin dışı içerikleri destekleyen çok modlu bileşenlerin sisteme entegre edilmesi ve yanıt sürelerini iyileştirmeye yönelik mimari optimizasyonların değerlendirilmesi hedeflenmektedir. Bu doğrultuda Akıllı Rehber, yerel dil ve müfredat gereksinimleriyle uyumlu yalın RAG mimarilerinin, eğitim odaklı yapay zekâ sistemleri için geliştirilebilir bir araştırma zemini sunduğuna işaret etmektedir.

KAYNAKLAR

- [1] Z. Liu, P. Agrawal, S. Singhal, V. Madaan, M. Kumar, and P. K. Verma, "LPITutor: an LLM based personalized intelligent tutoring system using RAG and prompt engineering," *PeerJ Computer Science*, vol. 11, Aug. 2025, doi: 10.7717/peerj-cs.2991.
- [2] L. Wong, "Gaita: A RAG System for Personalized Computer Science Education," Dec. 2024, doi: 10.35542/osf.io/97nmg.
- [3] J. Swacha and M. Gracel, "Retrieval-Augmented Generation (RAG) Chatbots for Education: A Survey of Applications," *Applied Sciences*, vol. 15, no. 8, p. 4234, Apr. 2025, doi: 10.3390/app15084234.
- [4] A. K. Topallı, "EkoBot: Türkçe Destekli Akıllı Sanal Akademik Danışman," *International Journal of Advances in Engineering and Pure Sciences*, vol. 37, no. 2, p. 196, Jun. 2025, doi: 10.7240/jeeps.1553974.
- [5] F. Miladi, V. Psyché, A. Diattara, N. E. Mawas, and D. Lemire, "Evaluating a GPT-4 and Retrieval-Augmented Generation-Based Conversational Agent to Enhance Learning Experience in a MOOC," p. 347, Jan. 2025, doi: 10.5220/0013366100003932.
- [6] Y. Lee, "Developing a computer-based tutor utilizing Generative Artificial Intelligence (GAI) and Retrieval-Augmented Generation (RAG)," *Education and Information Technologies*, vol. 30, no. 6, p. 7841, Nov. 2024, doi: 10.1007/s10639-024-13129-5.
- [7] S. Budak and S. Aslan, "AI-Powered GPT-Based University-Specific Chat Assistant: UniROBO," *NATURENGS MTU Journal of Engineering and Natural Sciences Malatya Turgut Ozal University*, Dec. 2024, doi: 10.46572/naturengs.1587879.
- [8] Z. Zhao, Z. Yin, J. Sun, and P. Hui, "Embodied AI-Guided Interactive Digital Teachers for Education," p. 1, Nov. 2024, doi: 10.1145/3680533.3697070.
- [9] D. İrem, P. Burak, and A. Seçil, "TULIP: Adapting Open-Source Large Language Models for Underrepresented Languages and Specialized Financial Tasks," *arXiv (Cornell University)*, Aug. 2025, doi: 10.48550/arxiv.2508.16243.

- [10] S. Es, J. James, L. Espinosa-Anke, and S. Schockaert, "Ragas: Automated Evaluation of Retrieval Augmented Generation," arXiv (Cornell University), Sep. 2023, doi: 10.48550/arxiv.2309.15217.
- [11] K. Papineni, "Machine Translation Evaluation: N-grams to the Rescue.," Language Resources and Evaluation, May 2002, Accessed: Oct. 2025. [Online]. Available: <http://www.lrec-conf.org/proceedings/lrec2002/pdf/347.pdf>
- [12] C.-Y. Lin, "ROUGE: A Package for Automatic Evaluation of Summaries," p. 74, Jul. 2004, Accessed: Oct. 2025. [Online]. Available: <http://citeseerx.ist.psu.edu/viewdoc/summary?doi=10.1.1.111.9426>
- [13] A. GAN et al., "Retrieval Augmented Generation Evaluation in the Era of Large Language Models: A Comprehensive Survey." 2025.