

# Türkçe Sağlık Danışmanlığında Yapay Zeka Devrimi: LLM Tabanlı Sanal Doktor Asistanlarının Geliştirilmesi

## Artificial Intelligence Revolution in Turkish Health Consultancy: Development of LLM-Based Virtual Doctor Assistants

Muhammed Kayra Bulut  
Bilgisayar Mühendisliği Bölümü  
Yıldız Teknik Üniversitesi  
İstanbul, Türkiye  
kayra.bulut@std.yildiz.edu.tr

Banu Diri  
Bilgisayar Mühendisliği Bölümü  
Yıldız Teknik Üniversitesi  
İstanbul, Türkiye  
diri@yildiz.edu.tr

**Özetçe** —Bu çalışma, Türkçe sağlık danışmanlığında dört farklı büyük dil modelinin (LLama2, LLama3 ve Mistral temelli) doktor-hasta yazılı iletişimindeki performanslarını incelemektedir. Modeller, hasta-doktor soru-cevap veri seti üzerinde eğitilmiş ve ince ayar yapılmıştır [1]. Performans değerlendirmesi için kullanılan metrikler, *ROUGE*, *Elo puanlaması*, *Kazanma yüzdesi* ve *Uzman değerlendirmesi*'dir. Karşılaştırmalı analiz sonucunda, SambaLingo-Turkish-Chat modeli yanıt doğruluğu ve bağlama uygunluk açısından başarıyla, Trendyol-LLM-7b-chat-v1.8 modeli işin etik kısmı da dikkate alınca daha başarılı olmuştur [14], [17]. Bu çalışma, Türkçe sağlık hizmetlerinde yapay zeka destekli sanal doktor asistanlarının potansiyelini göstermekte ve Türkçeye özgü tıbbi sohbet robotlarının geliştirilmesine katkıda bulunmaktadır.

**Anahtar Kelimeler**—Doğal dil işleme, Tıbbi yapay zeka, Türkçe sağlık hizmetleri, BDM ince ayarı, Doktor-hasta iletişimi, Karşılaştırmalı model değerlendirmesi

**Abstract**—This study examines the performance of four different large language models (LLama2, LLama3, and Mistral-based) in doctor-patient written communication in Turkish health counseling. The models were trained and fine-tuned on a patient-doctor question-answer dataset [1]. The metrics used for performance evaluation include *ROUGE*, *Elo rating*, *Winning percentage*, and *Expert evaluation*. The comparative analysis results indicate that the SambaLingo-Turkish-Chat model was successful in terms of response accuracy and contextual relevance, while the Trendyol-LLM-7b-chat-v1.8 model proved to be more successful when considering the ethical aspects of the task [14], [17]. This study demonstrates the potential of AI-powered virtual doctor assistants in Turkish healthcare services and contributes to the development of Turkish-specific medical chatbots.

**Keywords**—Natural language processing, Medical AI, Turkish healthcare, LLM fine-tuning, Doctor-patient communication, Comparative model evaluation

### I. GİRİŞ

Yapay zeka ve doğal dil işleme teknolojilerindeki hızlı gelişmeler, sağlık hizmetleri alanında yeni bir çığır açma potansiyeline sahiptir. Özellikle büyük dil modellerinin (LLM) tıbbi uygulamalarda kullanılabilme potansiyeli, yakın bir gelecekte sağlık danışmanlığına ucuz ve hızlı erişim anlamına gelmektedir. Bu çalışma, Türkçe sağlık danışmanlığında dört farklı büyük dil modelinin hasta ile iletişiminin performansını incelemektedir. Doğal dil işleme alanındaki ilerlemeler, bilhassa sağlık sektöründe önemli uygulama alanları bulmaktadır. Hasta-doktor iletişiminin iyileştirilmesi, tıbbi metinlerin anlaşılabilirliğinin artırılması ve sağlık okuryazarlığının geliştirilmesi gibi birçok alanda dil modellerinin fayda potansiyelleri araştırılmaktadır. Lakin, bu gelişmeler genelde İngilizce gibi kaynak açısından zengin diller için olmuştur. Türkçe gibi görece daha az kaynağa sahip diller için benzer seviyede modeller şu anda geliştirilmemiştir. Türkçe özelinde yapılan çalışmalar sınırlı olmakla beraber, son yıllarda bu alanda önemli adımlar atılmıştır. Mesela, Schweter tarafından geliştirilen BERTurk modelleri, Türkçe metinler üzerinde eğitilmiş ve çeşitli doğal dil anlama görevlerinde gayet kabul edilebilir neticeler elde etmiştir [3]. Ayrıca, Amasyalı ve arkadaşlarının çalışmasında, birçok açık kaynaklı Türkçe dil modeli, bağlamda öğrenme ve soru cevaplama başarıları bakımından kıyaslanmıştır [12]. Bu çalışmada, LLama2, LLama3 ve Mistral tabanlı dört ayrı model kullanılmıştır:

- 1) Trendyol-LLM-7b-chat-v1.8
- 2) Turkish-LLama-8b-v0.1
- 3) Meta-LLama-3-8B
- 4) SambaLingo-Turkish-Chat

Bu modeller, Türkçe hasta-doktor soru-cevap veri kümesi üzerinde eğitilmiş ve modellerin ince ayarı yapılmıştır [1]. Bu işlem yapılırken LoRA yöntemi kullanılmıştır. Kullanılan veri kümesi, gerçek hasta-doktor verilerinden oluşan 321.179

soru-cevap çiftinden oluşmaktadır. Çalışmamız, Türkçe sağlık danışmanlığı uygulamalarında yapay zeka kullanımının potansiyelini ve sınırlarını ortaya koymayı amaçlamaktadır. Bu, bilhassa Türkçe konuşan hastalar için yapay zeka destekli sağlık danışmanlığı sistemlerinin geliştirilmesinde mühim bir adım olacaktır. Ayrıca, dile özgü tıbbi yapay zeka asistanlarının başarımını değerlendirerek, gelecekteki araştırmalar için bir temel oluşturacaktır. Bu çalışmanın önemi, sadece teknolojik gelişmelerin sağlık alanına uygulanmasıyla sınırlı değildir. Aynı zamanda, Türkçenin teknolojik gelişmelerle birlikte nasıl evrildiğini ve bu gelişmelerin dil üzerindeki etkilerini de dolaylı olarak incelemektedir. Bu bağlamda, çalışmamız Türkçe'nin dijital çağdaki konumunu güçlendirmeye ve dil teknolojilerinin gelişimine katkıda bulunmayı amaçlamaktadır.

Çalışmanın devamında, ikinci bölümde *İlgili Çalışmalar* detaylı bir şekilde incelenecek, üçüncü bölümde kullanılan *Materyaller ve Metodlar* açıklanacak, dördüncü bölümde elde edilen *Deneysel Sonuçlar* sunulacak ve son olarak beşinci bölümde çalışmanın *Sonuçları* ve gelecekteki araştırma yönleri tartışılacaktır.

## II. İLGİLİ ÇALIŞMALAR

Doğal dil işleme alanında son zamanlarda yaşanan gelişmeler, özellikle de büyük dil modellerinin birçok görevlerde gösterdiği başarılar takdire şayandır. Ancak bu gelişmeler çoğunlukla kaynak açısından zengin olan İngilizce için gerçekleşmiş, Türkçe gibi görece daha az kaynağa sahip diller için benzer seviyede modeller daha düşük performans göstermektedir. Aynı zamanda çok dilli destekleyen modelleri kullanabilmek için çok büyük donanım ve yüksek hesaplama gücüne ihtiyaç duyulmaktadır. Bu sebeplerden dolayı insanlar bu modelleri kullanabilmek için internet ortamında verilerini paylaşmak zorunda kalmaktadır. Bu durum sağlık verileri gibi özel verilerini paylaşmak istemeyen insanlar için sıkıntı teşkil etmektedir. Bundan dolayı daha küçük ve dile özel modellerin geliştirilmesi elzemdir.

Türkçe için özel olarak geliştirilen dil modellerine bakıldığında, Schweter [3] tarafından geliştirilen BERTurk modelleri kullanılabilir ve hafif modellerdir. Bu modeller, BERT mimarisini temel alarak Türkçe metinler üzerinde eğitilmiş ve çeşitli doğal dil anlama görevlerinde güzel sonuçlar elde etmiştir. Lakin bu modeller sadece kodlayıcı (encoder) mimariye sahip olduğu için, metin üretme işlerinde kullanılamamaktadır.

Çok dilli modeller arasında mBERT [4], XLM-R [5], mT5 [6] ve mBART [7] gibi modeller Türkçeyi de içermektedir. Ama bu modellerin Türkçe özelindeki başarıları Türkçe için özel eğitilmiş modellerin gerisinde kalmaktadır [8], [9]. Türkçe dil modelleri üzerine yapılan son çalışmalardan biri de, farklı dil modellerinin Türkçe başarımlarını karşılaştırmaktadır. Amasyalı ve arkadaşlarının çalışmasında [12], birçok açık kaynaklı Türkçe dil modelleri, bağlamda öğrenme ve soru cevaplama başarıları açısından Amasyalı ve arkadaşları tarafından mukayese edilmiştir.

Büyük dil modellerinin ön eğitim (pre-train) yöntemleri konusunda da birçok yaklaşım önerilmiştir. Örneğin T5 modeli [10] metin parçalarını bozma (span corruption) yöntemini kullanırken, UL2 yaklaşımı [11] farklı ön eğitim perspektiflerini birleştiren Mixture-of-Denoisers (MoD) yaklaşımını

önermiştir. Bunun yanında, büyük dil modellerinin sağlık alanındaki soru-cevap sistemlerine olan etkisi de son çalışmalarla araştırılmıştır. Gökçimen ve Das [13], dönüştürücü temelli modellerin sağlık verileriyle optimize edilmiş başarımlarını kıyaslayarak, denoising mekanizmaları ve ayrıştırılmış dikkat mekanizmalarının etkilerini incelemiştir.

Bu çalışmada, büyük dil modellerinin Türkçe hasta-doktor soru-cevap veri kümesiyle eğitildikten sonraki performansları kıyaslanmış ve incelenmiştir. Bilhassa, bu modellerin Türkçe dilinde hastaların tıbbi sorularına ne kadar etkili cevap veribildikleri kıymetlendirilecek ve farklı modeller birbirleriyle mukayese edilecektir.

## III. MATERYALLER VE METODLAR

Çalışmada, dört farklı büyük dil modelinin Türkçe sağlık danışmanlığındaki performansını ölçmek için gayet kapsamlı bir yöntemler manzumesi kullanılmıştır. Araştırmanın temel bileşenleri veri seti, model seçimi ve eğitimi, ve değerlendirme kriterlerinden oluşmaktadır.

### A. Veri Kümesi

Çalışmada kullanılan veri seti, Hugging Face platformunda bulunan "patient-doctor-qa-tr-321179" adlı özel bir Türkçe tıbbi soru-cevap veri kümesidir [1]. Bu veri kümesi, gerçek doktor-hasta verilerinden oluşan 321.179 soru-cevap çiftinden oluşmaktadır. Veri setinin içeriği, çeşitli tıbbi konuları ve sağlık danışmanlığı soru-cevaplarını kapsamaktadır. Bu veri kümesi doktorsitesi veri kümesinin [2] temizlenmesiyle elde edilen patient-doctor-qa-tr-321179 veri kümesinin [28], çeviri veri kümeleri olan patient-doctor-qa-tr-5695 [26], patient-doctor-qa-tr-95588 [25] ve patient-doctor-qa-tr-19583 [27] veri kümeleriyle birleştirilmesi sonucunda oluşturulmuştur.

### B. Model Seçimi ve Eğitimi

Araştırmada, LLama2, LLama3 ve Mistral tabanlı dört farklı büyük dil modeli kullanılmıştır:

- Meta-Llama-3-8B (**Model 1**) [16]
- SambaLingo-Turkish-Chat (**Model 2**) [17]
- Trendyol-LLM-7b-chat-v1.8 (**Model 3**) [14]
- Turkish-Llama-8b-v0.1 (**Model 4**) [15]

Bu modeller, özel Türkçe hasta-doktor soru-cevap veri kümesi üzerinde ince ayar yapılmıştır. Eğitim süreci, her modelin özel mimarisi ve hiperparametreleri dikkate alınarak optimize edilmiştir. Hiperparametrelerin en önemlileri şu şekilde sıralanabilir:

- **Döngü (Epoch):** Model 1 için 1 diğer modeller içinse 2 olarak seçilmiştir.
- **Batch size:** Tüm modeller için 128.
- **Optimizer:** Tüm modeller için 8-bit AdamW.
- **Learning rate:** Tüm modeller için  $1e-4$ .
- **seed:** Tüm modeller için 3407.

### C. Değerlendirme Metrikleri

Modellerin performansını ölçmek için dört farklı ölçüt kullanılmıştır:

- 1) **ROUGE**(Özet Değerlendirme için Geri Çağırma Odaklı Yedek Çalışma): Üretilen sonuçların, kaynak sonuçlarla örtüşme derecesini ölçmek için n-gram, alt dizi ve kelime çifti benzerlikleri gibi birçok yöntem kullanır.
- 2) **Elo puanlaması**: Modellerin objektif performansını ölçmek için kullanılan bir derecelendirme sistemidir. Bu sistem, satranç oyuncularının performansını değerlendirmek için kullanılan Elo derecelendirme sistemine dayanmaktadır [18]. *Derece güncelleme formülü* Eşitlik 1'deki gibidir. Derece güncellemesini kullanan *elo hesaplama formülü* Eşitlik 2'deki gibidir.

$$R' = R + 32 \cdot (S - E) \quad (1)$$

$$Elo = \frac{1}{1 + 10^{\frac{R_{\text{opponent}} - R}{400}}} \quad (2)$$

Elo hesaplanırken  $K$  değeri 32 ve *başlangıç puanı* 1200 alınmıştır.

- 3) **Kazanma yüzdesi**: Her modelin diğer modellere karşı kazanma oranını gösteren ölçüttür. Bu oran, modellerin birbirleriyle gelişmiş yapay zekalar hakemliğinde karşılaştırılması sonucunda elde edilmiştir.
- 4) **Uzman değerlendirmesi**: Doktorlar tarafından -10 ile 10 arasında puanlama yapılarak model cevaplarının gerçeğe ve etiğe uygunluğu değerlendirilmiştir. Bu değerlendirme, modellerin gerçek dünya uygulamalarındaki potansiyel faydasını ölçmek için kullanılmıştır.

Bu ölçütler, modellerin hem teknik performansını hem de pratik uygulanabilirliğini değerlendirmek için seçilmiştir.

### D. Karşılaştırma Metodolojisi

1) **ROUGE**: Hesaplama, eğitimde kullanılmayan 32.119 veriden oluşan bir test verisi kullanılmıştır.

- İlk olarak modellerin rastgelelikleri kapatılmıştır.
- Sonrasında her modele 32.119 veri için cevaplar üretilmiştir.
- Üretilen verilerle test verisindeki cevaplar kıyaslanmıştır.

2) **Elo ve Kazanma Yüzdesi**: Modellerin performansını karşılaştırmak için, GPT-4o, LLaMA3.1, Microsoft Copilot, Google Gemini ve Anthropic Claude 3.5 Sonnet gibi gelişmiş dil modelleri hakem olarak seçilmiştir [19]–[23]. Bu seçim tüm modellerin, LMYS Chatbot Arena Leaderboard'daki sıralaması göz önünde bulundurularak yapılmıştır [24].

Karşılaştırma süreci şu şekilde gerçekleştirilmiştir:

- Her model çifti için 20 hasta sorusu seçilmiştir.
- Modeller bu sorulara cevap vermiştir.
- Tüm modellerin cevapları 2'li eşleştirilmiştir. Toplam 120 eşleşme olmuştur.

- Hakem modeller, bu eşleşmelerin her birisi için bir kazanan belirlemiştir.
- Bu sonuçlar kullanılarak Elo puanlaması ve kazanma yüzdesi hesaplanmıştır.

3) **Uzman Değerlendirmesi**: Uzman değerlendirmesi için, çeşitli uzmanlık alanlarından birçok doktora danışılmıştır. Bu değerlendirme süreci şu şekilde gerçekleştirilmiştir:

- 20 adet hasta sorusu seçilmiştir.
- Her model bu sorulara cevap vermiştir.
- Toplam  $20 \times 4 = 80$  cevap elde edilmiştir.
- Uzman doktorlar, modellerin verdiği cevapların kalitesini -10 ile +10 arasında puanlamıştır.
- Puanlama -10'a yaklaştıkça modelin cevabı zararlı ve hastayı yanlış yönlendiriyor demektir.
- Puanlama +10'a yaklaştıkça modelin cevabı yararlı ve soruyu eksiksiz bir şekilde cevapladı demektir.
- Puanlama 0'a yaklaştıkça modelin cevabı ne yararlı ne zararlı yani faydasız demektir.

Doktorlardan toplam 1536 cevap alınmıştır. Cevap alınan doktorlar 12 farklı kurumda görev yapmaktadırlar. Toplam 20 farklı doktor sorulara cevap vermiştir. Bu doktorların unvan dağılımıysa;

- Stajyer Doktor (6 Adet)
- İntern Doktor (4 adet)
- Asistan Doktor (4 Adet)
- Pratisyen Hekim (2 Adet)
- Uzman Doktor (4 Adet)


Bu basit ama kapsamlı değerlendirme yöntemleri, modellerin hem teknik performansını hem de gerçek hayattaki uygulanabilirliğini test etmeyi ve göstermeyi amaçlamaktadır. Hakem modellerin kullanımı, değerlendirme sürecine objektif bir bakış açısı getirirken, uzman doktorların katılımı, modellerin gerçek dünya uygulamalarındaki potansiyel faydasını ölçmek için çok önemlidir.

## IV. DENEYSEL SONUÇLAR

Bu bölümde, karşılaştırılan modellerin başarı sonuçları sunulmaktadır. Analiz, hakem modellerin ve uzman doktorların değerlendirmelerine dayalı olarak yapılmıştır. Sonuçlar, model performansını çeşitli ölçütlerle göstermektedir.

### A. Model Performansı - ROUGE


Şekil 1'de her bir modelin ROUGE puanları gösterilmektedir. ROUGE-L puanlarına göre 0,1192 puanla **Model 2** en yüksek puana sahip modeldir. Ona çok yakın olan 0,1046 puanla **Model 3** ikinci sırada gelmektedir. **Model 4** ve **Model 1**'in arasındaki puan farklı anlamsız denebilecek derecede azdır. Benzer şekilde ROUGE-1, ROUGE-2 ve ROUGE-Lsum puanlarında da durum aynıdır. Hepsinde sıralama **Model 2**, **Model 3**, **Model 4** ve sonrasında **Model 1** şeklindedir.



Şekil 1: Her bir modelin ROUGE puanları.

### B. Model Performansı - Elo Puanları


Elo puanlama sistemi, modellerin göreceli gücünü belirlemek için kullanılmıştır. Şekil 2'e baktığımızda *GPT-4o*'nun değerlendirmesine göre, en yüksek puanı 1277 Puan ile **Model 2** almıştır. Onun ardından ufak bir farkla **Model 3**, sonrasında **Model 1** gelmektedir. **Model 4** ise sonuncu olmuştur. Bu sıralama *Gemini* ve *Claude 3.5 Sonnet* modelleri için de aynıdır. *LLama3.1* modeline göre en yüksek puanı 1263 puanla **Model 3** almıştır. Onun hemen ardından 1258 puan ile **Model 2** gelmektedir. *LLama3.1* modeline göre 3. sırayı **Model 1** alırken sonunculuğuysa yine **Model 4** almıştır. *Copilot* modelinin hakemliğine göreyse 1. model açık ara farkla **Model 2** olmuştur. Onun ardından 2. olarak **Model 3** gelmiştir. Onun hemen ardından diğer sonuçlardan farklı olarak **Model 4** gelirken bu sefer **Model 1** sonuncu olmuştur. Bu sonuçlara bakıldığında genel olarak **Model 2**'nin en başarılı model olduğunu, hemen ardından **Model 3**'ün geldiğini ve bunları ve **Model 1** ve **Model 4**'ün takip ettiğini söyleyebiliriz.



Şekil 2: Her bir modelin Elo puanları.

### C. Model Performansı - Kazanma Yüzdesi

Her bir modelin karşılaştırmalarda ne kadar başarılı olduğunu göstermek için kazanma yüzdesi hesaplanmıştır. Şekil 3'e baktığımızda *GPT-4o*'nun değerlendirmesine göre, en yüksek kazanma oranına sahip model %63,33 ile **Model 2**'dir. Onun ardından %46,67 ile **Model 3**, sonrasında **Model 1** gelmektedir. **Model 4** ise sonuncu olmuştur. Bu sıralama *Claude 3.5 Sonnet* modeli için de aynıdır. *LLama3.1* modeline göre en yüksek kazanma oranına sahip modeller %56,67 ile **Model 2** ve **Model 3**'tür. Bunların hemen ardından %46,67 kazanma oranı ile **Model 1** gelmektedir. *LLama3.1* modeline göre sonunculuğu yine **Model 4** almıştır. *Copilot* modelinin hakemliğine göreyse 1. model açık ara farkla **Model 2** olmuştur. Onun ardından 2. olarak **Model 3** gelmiştir. Üçüncü olan modelse diğer sonuçlardan farklı olarak ufak bir farkla **Model 4** olmuştur. **Model 1** ise %31,67 kazanma oranıyla sonuncu olmuştur. *Gemini* modelinin hakemliğine göreyse 1. model %63,33 ile yine **Model 2** olmuştur. Ama 2. sırayı bu kez %51,57 kazanma oranıyla **Model 1** almıştır. 3. sırayıysa ufak bir farkla **Model 3** alırken **Model 4** yine sonuncu olmuştur. Bu sonuçlara bakıldığında yine **Model 2**'nin en başarılı model olduğunu, hemen ardından **Model 3**'ün geldiğini ve bunları ve **Model 1** ve **Model 4**'ün takip ettiğini söyleyebiliriz.




Şekil 3: Her bir modelin kazanma yüzdesi.

### D. Uzman Değerlendirmeleri

Uzman doktorlar tarafından yapılan değerlendirmelere dayalı olarak, modellerin insana yakınlık derecesi ölçülmüştür. Şekil 4'e bakıldığında zaman uzmanlara göre en iyi model 3,25 puanla **Model 2**, 2. sıradaki model 2,79 puanla **Model 3** olmuştur, Model 3'ün ardından 2,43 puanla **Model 1** gelmektedir. İlk 3 model arasında azımsanmayacak bir fark olsa da bu modellerin sonuç itibarıyla yararlı modeller olduğu söylenebilir. Ama -0,23 puan alan **Model 4**, hem diğer modellere göre çok daha düşük puan almıştır, hem de sonuç itibarıyla doktorlar tarafından zararı yararından daha çok olarak değerlendirilmiştir.

Tablo I ise, doktorlar tarafından cevaplara verilen puanların yararlı, nötr ve zararlı olarak sınıflandırılmış halini göstermektedir. Tablo I'e bakıldığında yararlı cevap oranında en yüksek oran %71,1 ile **Model 2**'de olmasına rağmen, en az



Şekil 4: Uzman değerlendirmelerine göre modellerin performansı.

zararlı cevap veren model %18,4 ile **Model 3** olmuştur. Sağlık konusunda, modellerin cevapları geriye dönülemez sıkıntılar oluşturabilir. Aynı zamanda etik de bu konunun ayrı bir problemi. Modellerin cevaplarının yararlı olması önemli olsa da, zararlı cevap almak istememek çok daha önemlidir. Bundan dolayı **Model 2**'nin başarısı ne kadar yüksek olsa da onun yerine **Model 3** tercih edilebilir.

TABLO I: Cevap Yarar Dağılımı

| Model                     | Yararlı (%) | Zararlı (%) | Nötr (%) |
|---------------------------|-------------|-------------|----------|
| Trendyol-LLM-7b-chat-v1.8 | 69,4        | 18,4        | 12,2     |
| Meta-Llama-3-8B           | 62,6        | 21,3        | 16,1     |
| Turkish-Llama-8b-v0.1     | 42,1        | 33,8        | 24,1     |
| SambaLingo-Turkish-Chat   | 71,1        | 21,1        | 7,8      |

#### E. Genel Sonuçlar

Tablo I kullanılarak yapılan analizlere dayanarak, çeşitli dil modellerinin hem teknik hem de pratik alanlarda nasıl performans gösterdiği ortaya konulmuştur. Hakem modellerin ve uzman doktorların değerlendirmeleri, modellerin geniş bir yelpazede nasıl değerlendirildiğini göstermektedir. Genel olarak en başarılı model **Model 2** olurken en başarısız modelse **Model 4** olmuştur. **Model 3** başarı anlamında 2. sıradayken **Model 1** ise sonuçların geneline göre 3. sıradadır. Ama etik kaygılar ve geri dönülemez sorunlar dikkate alındığında gerçek uzman değerlendirmelerine göre **Model 3** daha kullanılabilir durumdadır. Bununla beraber sentetik testlerin genel sonuçlarıyla, gerçek uzmanların sonuçları arasında (ne kadar aynı oranda olmasa da) bir korelasyon olduğundan söz edilebilir.

#### V. SONUÇ

Bu çalışmada, Türkçe sağlık danışmanlığında dört farklı büyük dil modelinin performansı karşılaştırılmıştır. Araştırmamızın sonuçları, **SambaLingo-Turkish-Chat** modelinin en iyi performansı gösterdiğini ortaya koymuştur. Bunu sırasıyla **Trendyol-LLM-7b-chat-v1.8**, **Meta-Llama-3-8B** ve **Turkish-Llama-8b-v0.1** modelleri takip etmiştir.

**SambaLingo-Turkish-Chat** modelinin üstün performansı, modelin Türkçe dilinde insan uyumlu bir sohbet modeli olarak

eğitilmiş olmasına atfedilebilir. Bununla beraber **Trendyol-LLM-7b-chat-v1.8** modelinin cevaplarının etiğe daha yakın olduğu ve bundan dolayı daha kullanılabilir bir model olduğu söylenebilir.

Bu analizler, Türkçe sağlık danışmanlığı alanında yapay zeka destekli sistemlerin kapasitesini göstermektedir. Bilhassa **SambaLingo-Turkish-Chat** ve **Trendyol-LLM-7b-chat-v1.8** modelleri, klinik ortamlarda hasta-doktor iletişimini verimli hale getirmek, sağlık bilgilerini daha ulaşılabilir, ucuz ve güvenilir hale getirmek ve hastaların sağlık sorularını yanıtlamak için kullanılabilir.

Çalışmanın bazı kısıtları bulunmaktadır. Öncelikle, hasta-doktor ilişkisinin hassaslığı nedeniyle etik sınırlamalar mevcuttur. Bu bağlamda, modelin hastayı yanıltmaması, hastaya faydasız cevap vermemesi, hastaya yanlış teşhis koymaması gereklidir. Bu tip cevapların çok düşük oranda olması bile, hayati öneme sahip olduğu için, kabul edilemez bir durumdur ve bu sorunların aşılması gerekir. Ayrıca, büyük modellerin eğitimi için gerekli donanım kısıtları ve yüksek kaliteli Türkçe tıbbi veri setlerinin sınırlı olması da önemli sıkıntılardır. Araştırma yaparken yeterli donanım kaynağına sahip olmayanların araştırmalarını yürütmesi mümkün değildir. Mesela eğitilen modellerin daha yüksek parametreye sahip varyasyonları da vardı ama donanım kısıtımız olduğu için en düşük varyasyonları eğiterek test edebildik. Donanım kısıtı maddi kaynak bulunarak aşılabılır durumda olsa dahi işin etik kısmı hala çözülebilmüş değildir. Etik sorunları da çözüldükten sonra, gelecekte daha kapsamlı ve temiz veri setleriyle daha büyük modellerin eğitilmesi mümkün olabilir.

Gelecekteki çalışmalar için, Sağlık Bakanlığı ile müşterek çalışmalar yürütülerek daha büyük ve kaliteli veri kümeleri oluşturulabilir. Ayrıca, farklı model mimarileri de test edilebilir. Bu çalışmalar, doktorların işini kolaylaştıracak ve sağlık hizmetlerine ulaşmayı kaliteli, ucuz ve hızlı hale getirecek yapay zeka destekli sistemlerin geliştirilmesine katkıda bulunabilir.

Bu çalışma, Türkçeye özgü model geliştirmenin önemini de göstermektedir. Sonuçlar, daha küçük modellerin bile Türkçe olarak eğitildiğinde gayet güzel performans sergileyebileceğini göstermektedir.

Sonuç olarak, bu çalışma Türkçe sağlık danışmanlığında büyük dil modellerinin kapasitesini ortaya koymuştur. İlerleyen araştırmalar, bu modellerin klinik uygulamalardaki etkinliğini artırmaya, etik standartları korumaya ve Türk sağlık sistemine entegrasyonunu kolaylaştırmaya odaklanmalıdır. Bu uğraşlar, gelecekte daha kişiselleştirilmiş, erişilebilir, ucuz ve verimli sağlık hizmetlerinin geliştirilmesi konusunda faydalı olacaktır.

#### VI. TEŞEKKÜR

Bu çalışmanın gerçekleştirilmesinde birçok değerli kişinin katkısı olmuştur. Öncelikle, tez danışmanım olan Prof. Dr. Banu Diri'ye teşekkürü borç bilirim. Takıldığım yerlerde sorulara içtenlikle cevap veren Prof. Dr. Mehmet Fatih Amasyalı, M. Ali Bayram, Arş. Gör. Himmet Toprak Kesgin'e teşekkür ediyorum.

Ayrıca, çalışmamız kapsamında sorularımızı sabırla yanıtlayan ve değerli zamanlarını ayıran tüm doktorlardan Allah razı olsun. Onların uzmanlığı, araştırmamızın kalitesini ve

gerçek dünya uygulamalarına olan uygunluğunu önemli ölçüde artırmıştır.

#### KAYNAKLAR

- [1] M. K. Bulut, "Patient Doctor Q&A TR 321179," 2024. [Online]. Available: <https://doi.org/10.5281/zenodo.12798934>
- [2] M. A. Bayram, "Türkçe Tıbbi Soru-Cevap Veri Seti," 2024. [Online]. Available: <https://zenodo.org/record/12770916>
- [3] S. Schweter, "BERTurk-BERT models for Turkish," Zenodo, vol. 2020, p. 3770924, 2020.
- [4] J. Devlin, "Bert: Pre-training of deep bidirectional transformers for language understanding," arXiv preprint arXiv:1810.04805, 2018.
- [5] A. Conneau, K. Khandelwal, N. Goyal, V. Chaudhary, G. Wenzek, F. Guzmán, E. Grave, M. Ott, L. Zettlemoyer, and V. Stoyanov, "Unsupervised cross-lingual representation learning at scale," arXiv preprint arXiv:1911.02116, 2019.
- [6] L. Xue, N. Constant, A. Roberts, M. Kale, R. Al-Rfou, A. Siddhant, A. Barua, and C. Raffel, "mT5: A massively multilingual pre-trained text-to-text transformer," arXiv preprint arXiv:2010.11934, 2020.
- [7] Y. Liu, J. Gu, N. Goyal, X. Li, S. Edunov, M. Ghazvininejad, M. Lewis, and L. Zettlemoyer, "Multilingual denoising pre-training for neural machine translation," Transactions of the Association for Computational Linguistics, vol. 8, pp. 726–742, 2020.
- [8] P. Rust, J. Pfeiffer, I. Vulić, S. Ruder, and I. Gurevych, "How good is your tokenizer? on the monolingual performance of multilingual language models," arXiv preprint arXiv:2012.15613, 2020.
- [9] D. Nozza, F. Bianchi, and D. Hovy, "What the [mask]? making sense of language-specific BERT models," arXiv preprint arXiv:2003.02912, 2020.
- [10] C. Raffel, N. Shazeer, A. Roberts, K. Lee, S. Narang, M. Matena, Y. Zhou, W. Li, and P. J. Liu, "Exploring the limits of transfer learning with a unified text-to-text transformer," Journal of machine learning research, vol. 21, no. 140, pp. 1–67, 2020.
- [11] Y. Tay, M. Dehghani, V. Q. Tran, X. Garcia, J. Wei, X. Wang, H. W. Chung, S. Shakeri, D. Bahri, T. Schuster, and others, "UL2: Unifying language learning paradigms," arXiv preprint arXiv:2205.05131, 2022.
- [12] E. Dogan, M. E. Uzun, A. Uz, H. E. Seyrek, A. Zeer, E. Sevi, H. T. Kesgin, M. K. Yuce, M. F. Amasyali, "Türkçe Dil Modellerinin Performans Karşılaştırması," Cosmos AI Research Group, Department of Computer Engineering, Yıldız Technical University, 2024.
- [13] T. Gokcimen, B. Das, "Comparison of Pre-trained Models for Optimized Transformer-Based Question Answering System," IEEE, 2024.
- [14] Trendyol, "Trendyol/Trendyol-LLM-7b-chat-v1.8," Available: <https://huggingface.co/Trendyol/Trendyol-LLM-7b-chat-v1.8>, Accessed: August 16, 2024.
- [15] ytu-ce-cosmos, "ytu-ce-cosmos/Turkish-Llama-8b-v0.1," Available: <https://huggingface.co/ytu-ce-cosmos/Turkish-Llama-8b-v0.1>, Accessed: August 16, 2024.
- [16] meta-llama, "meta-llama/Meta-Llama-3-8B," Available: <https://huggingface.co/meta-llama/Meta-Llama-3-8B>, Accessed: August 16, 2024.
- [17] sambanovasystems, "sambanovasystems/SambaLingo-Turkish-Chat," Available: <https://huggingface.co/sambanovasystems/SambaLingo-Turkish-Chat>, Accessed: August 16, 2024.
- [18] Elo, Arpad E., and Sam Sloan. "The rating of chessplayers: Past and present." (No Title) (1978).
- [19] OpenAI, "GPT-4o: OpenAI's Latest Language Model," Available: <https://openai.com/index/hello-gpt-4o/>, Accessed: August 16, 2024.
- [20] Meta AI, "LLaMA 3.1: Meta's Next-Generation Large Language Model," Available: <https://huggingface.co/meta-llama/Meta-Llama-3.1-70B>, Accessed: August 16, 2024.
- [21] Microsoft, "GitHub Copilot: AI-Powered Code Completion by Microsoft," Available: <https://copilot.microsoft.com/>, Accessed: August 16, 2024.
- [22] Google, "Gemini: Google's AI Model for Multimodal Understanding," Available: <https://deepmind.google/technologies/gemini/pro/>, Accessed: August 16, 2024.
- [23] Anthropic, "Claude: A New AI Assistant by Anthropic," Available: <https://www.anthropic.com/news/claude-3-5-sonnet>, Accessed: August 16, 2024.
- [24] LMSYS Chatbot Arena, "LMSYS Chatbot Arena Leaderboard," Available: <https://chat.lmsys.org/?leaderboard>, Accessed: August 18, 2024.
- [25] M. K. Bulut, "Patient-Doctor QA Dataset (TR)," Hugging Face, <https://huggingface.co/datasets/kayrab/patient-doctor-qa-tr-95588>, 2024.
- [26] M. K. Bulut, "Patient-Doctor QA Dataset (TR)," Hugging Face, <https://huggingface.co/datasets/kayrab/patient-doctor-qa-tr-5695>, 2024.
- [27] M. K. Bulut, "Patient-Doctor QA Dataset (TR)," Hugging Face, <https://huggingface.co/datasets/kayrab/patient-doctor-qa-tr-19583>, 2024.
- [28] M. K. Bulut, "Patient-Doctor QA Dataset (TR)," Hugging Face, <https://huggingface.co/datasets/kayrab/patient-doctor-qa-tr-321179>, 2024.